

UNIVERSIDAD PERUANA DE CIENCIAS APLICADAS

FACULTAD / PROGRAMA ACADÉMICO: [COMPLETAR]

CURSO: [NOMBRE DEL CURSO] · DOCENTE: [COMPLETAR]

ARQUITECTURAS CNN PARA LA CLASIFICACIÓN DE CÉLULAS SANGUÍNEAS

Comparación de LeNet-5 y VGG-11, Batch Normalization
y transferencia de aprendizaje con ResNet-18

TRABAJO PRÁCTICO — SEMANA 6 (PC2)

AUTOR

Mucha Álvarez, Diego Fabrizio · u202317069

REPOSITORIO PÚBLICO

[https://github.com/usuario/dl-semana6-apellidos]

Lima, [fecha de presentación]

1. Introducción

La clasificación automática de leucocitos en imágenes microscópicas requiere distinguir características morfológicas y cromáticas sutiles. Las redes neuronales convolucionales (CNN) permiten aprender representaciones de esas estructuras; aquí se evalúan con finalidad académica, no como herramienta de diagnóstico clínico.

El conjunto Blood Cell Images de Kaggle [6], con licencia CC0, comprende EOSINOPHIL, LYMPHOCYTE, MONOCYTE y NEUTROPHIL. El análisis exploratorio comprobó 12 444 imágenes RGB de 320 × 240 píxeles: 9 957 en TRAIN oficial y 2 487 en TEST oficial. Las cuatro clases están aproximadamente equilibradas.

1.1. Objetivo general

Implementar y comparar LeNet-5 y VGG-11, con y sin Batch Normalization (BN), estudiar su estabilidad frente al aumento de la tasa de aprendizaje y evaluar tres estrategias de transferencia con ResNet-18 preentrenada.

1.2. Preguntas de investigación

Se investigan tres cuestiones: (i) rendimiento y costo de LeNet y VGG; (ii) efecto de BN sobre convergencia y sensibilidad a la tasa de aprendizaje; y (iii) utilidad de congelar o ajustar parcialmente/totalmente ResNet-18 con un conjunto de datos limitado.

2. Metodología

2.1. Datos, particionado y preprocesamiento

Se conservó TRAIN/TEST oficial, excluyendo TEST_SIMPLE. El 20 % aproximado de TRAIN se destinó a validación mediante partición estratificada que conserva juntos los hashes de imágenes idénticas (semilla 42). La auditoría registró 12 444 imágenes, ningún duplicado exacto ni hashes compartidos entre TRAIN y TEST. No identifica, en cambio, pacientes ni aumentos preexistentes de una misma célula.

El notebook 01 obtuvo 7 965 imágenes para entrenamiento, 1 992 para validación y 2 487 para test; la Tabla 1 muestra el desglose por clase.

Tabla 1. Distribución real de imágenes por clase y partición (notebook 01).

Partición	EOSINOPHIL	LYMPHOCYTE	MONOCYTE	NEUTROPHIL	Total
Entrenamiento	1 998	1 986	1 982	1 999	7 965
Validación	499	497	496	500	1 992
Test oficial	623	620	620	624	2 487

Las CNN desde cero reciben imágenes RGB redimensionadas a 64 × 64 y normalizadas con media y desviación 0,5; ResNet-18 recibe 224 × 224 y normalización ImageNet. Solo el conjunto de entrenamiento usa volteos horizontal/vertical y rotaciones ±15°. El cambio de relación de aspecto (desde 320 × 240) puede deformar rasgos morfológicos.

2.2. Arquitecturas convolucionales

LeNet-5 [1] utiliza dos bloques convolución–average pooling, activaciones tanh y tres capas densas (120, 84 y 4 salidas). VGG-11 simplificada [3] conserva ocho convoluciones, pero reduce los filtros y utiliza una cabeza densa 1 024 → 512 → 256 → 4. BN se incorpora después de cada convolución. AlexNet [2] se considera antecedente, no un experimento de esta entrega.

Tabla 2. Arquitecturas y parámetros verificados (notebook 02).

Modelo	Entrada	Canales convolucionales	Capas FC	Parám.
LeNet-5	64×64×3	6, 16	120, 84, 4	337 976
LeNet-5 + BN	64×64×3	6, 16	120, 84, 4	338 020
VGG-11	64×64×3	32, 64, 128, 128, 256, 256, 256, 256	512, 256, 4	2 963 396
VGG-11 + BN	64×64×3	Iguales a VGG-11	512, 256, 4	2 966 148

2.3. Protocolo de entrenamiento y análisis de BN

Los nueve experimentos (75 épocas) utilizaron semilla 42, batch 64 y weight decay 10^{-4}. Las CNN se entrenaron con SGD (momentum 0,9) durante diez épocas, y ResNet-18 con Adam durante cinco. Se utilizó un bucle de entrenamiento propio, sin scheduler, early stopping ni recorte de gradientes. El notebook 02 ejecutó las CNN en CUDA; el notebook 03 ejecutó ResNet en CPU.

Tabla 3. Hiperparámetros y presupuesto experimental.

Grupo	Modelos / estrategia	Optimizador	LR	Épocas
Desde cero	LeNet, LeNet + BN, VGG-11, VGG-11 + BN	SGD, momentum 0,9	0,01	10 c/u
Control BN/LR	LeNet y LeNet + BN	SGD, momentum 0,9	0,1	10 c/u
Transferencia	Solo capa FC	Adam	0,001	5
Transferencia	layer3, layer4 y FC	Adam	0,0001	5
Transferencia	Modelo completo	Adam	0,00001	5

Los pares ±BN comparten particiones, inicializaciones comparables, orden de lotes y aumentos. El umbral de convergencia es la primera época con accuracy de validación ≥ 80 %. Para LeNet se repite el entrenamiento con LR = 0,1 (frente a 0,01); estabilidad numérica significa ausencia de NaN o Inf, no ausencia de oscilaciones.

2.4. Transfer Learning con ResNet-18

Se empleó ResNet-18 preentrenada en ImageNet (IMAGENET1K_V1) [4] con clasificación final de cuatro clases: (i) solo FC entrenable (feature extraction); (ii) layer3, layer4 y FC (ajuste parcial); y (iii) todas las capas entrenables (ajuste total). Los learning rates fueron 10^{-3}, 10^{-4} y 10^{-5}; las estadísticas BN se mantuvieron congeladas.

2.5. Selección, métricas y reproducibilidad

Cada época candidata se evaluó mediante accuracy de validación (desempate por menor pérdida). La evaluación en test se reservó al checkpoint seleccionado. Se reportan accuracy, macro-F1, recall por clase, matriz de confusión y segundos medios por época (carga + entrenamiento; sin validación ni guardado). Los tiempos de las CNN (GPU) no son directamente comparables con los de ResNet (CPU).

3. Resultados

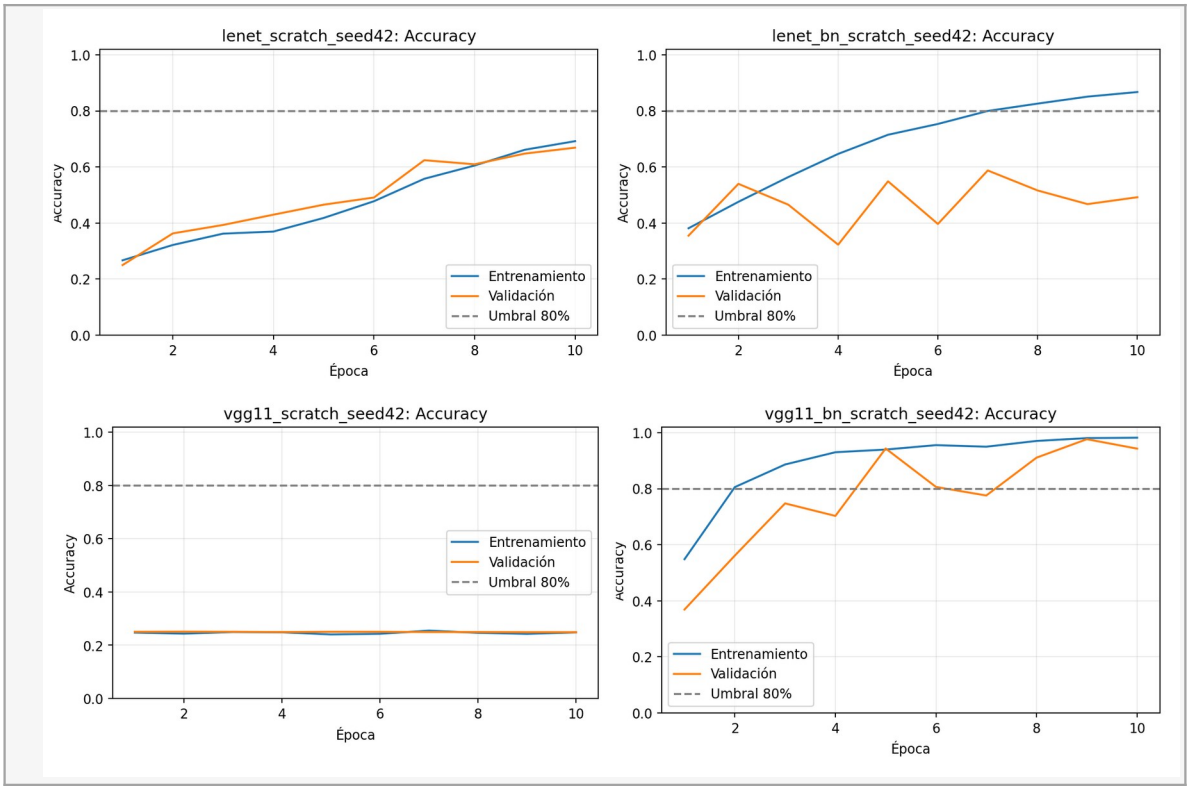
3.1. Comparación de cuatro CNN entrenadas desde cero

El notebook 02 completó las cuatro CNN con LR = 0,01 (Tabla 4). VGG-11 + BN fue la mejor CNN desde cero por validación (97,64 %) y alcanzó 81,14 % de accuracy y 82,13 % de macro-F1 en test. VGG-11 sin BN quedó cerca del azar (25,09 % en test), mientras LeNet y LeNet + BN alcanzaron 46,72 % y 39,89 %, respectivamente.

Tabla 4. Comparación de CNN desde cero; accuracy y macro-F1 en porcentaje.

Modelo	Parámetros	s/época	Accuracy val.	Accuracy test	Macro-F1 test
LeNet-5	337 976	79,66	66,87 %	46,72 %	44,66 %
LeNet-5 + BN	338 020	21,68	58,73 %	39,89 %	40,38 %
VGG-11	2 963 396	23,73	25,10 %	25,09 %	10,03 %
VGG-11 + BN	2 966 148	23,83	97,64 %	81,14 %	82,13 %

Figura 1. Curvas originales de accuracy train/val: LeNet-5, LeNet-5 + BN, VGG-11 y VGG-11 + BN (notebook 02).



La Figura 1 muestra que la validación de VGG-11 sin BN permanece próxima al 25 %, mientras VGG-11 + BN supera el 80 % por primera vez en la época 5. LeNet + BN mejora su accuracy de entrenamiento, pero la validación oscila ampliamente; la pérdida y el accuracy son más coherentes en LeNet sin BN, aunque con menor rendimiento global.

El tiempo atípico de 79,66 s/época de LeNet sin BN no permite inferir que incorporar BN acelere 3,7 veces esta red: hay variación del entorno de ejecución. La selección del modelo se hizo exclusivamente por validación y no por test.

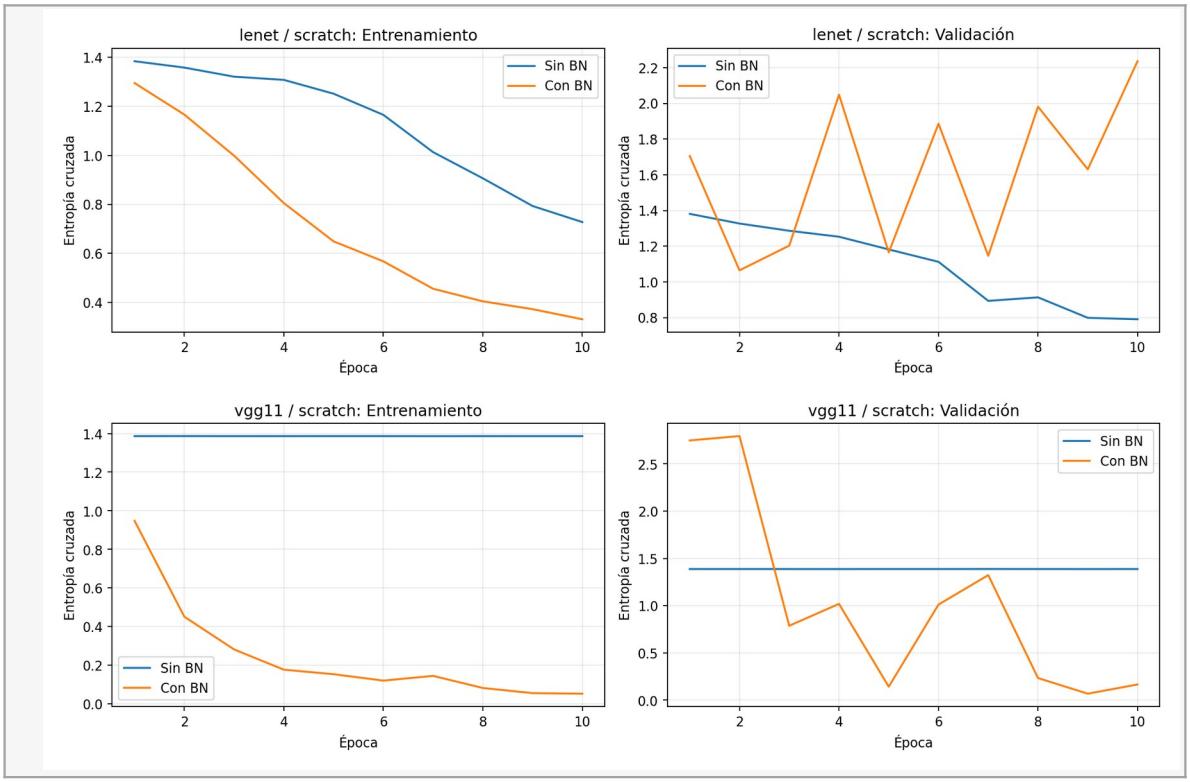
3.2. Efecto de Batch Normalization y de la tasa de aprendizaje

Se compararon LeNet y VGG sin/con BN con LR = 0,01; adicionalmente LeNet ±BN con LR = 0,1. Ninguna ejecución presentó NaN/Inf, pero ello no implica curvas de validación estables. Solo VGG-11 + BN alcanzó el umbral de 80 % de validación (época 5).

Tabla 5. Efecto de BN y LR en la mejor accuracy de validación (notebook 02).

Arquitectura	BN	LR	Época ≥80 % val.	Mejor acc. val.	Estabilidad
LeNet-5	No	0,01	No alcanzado	66,87 %	Sin NaN/Inf
LeNet-5	Sí	0,01	No alcanzado	58,73 %	Sin NaN/Inf
LeNet-5	No	0,1	No alcanzado	26,96 %	Sin NaN/Inf
LeNet-5	Sí	0,1	No alcanzado	66,47 %	Sin NaN/Inf
VGG-11	No	0,01	No alcanzado	25,10 %	Sin NaN/Inf
VGG-11	Sí	0,01	5	97,64 %	Sin NaN/Inf

Figura 2. Comparación de pérdida en train/val de LeNet y VGG, con y sin BN, LR = 0,01 (notebook 02).



BN normaliza las activaciones por minibatch y aprende escala y desplazamiento. Ioffe y Szegedy [5] la motivaron como una forma de mitigar el Internal Covariate Shift; las curvas permiten estudiar estabilidad y generalización, pero no medir directamente ese fenómeno.

El efecto dependió de la arquitectura: BN disminuyó la validación de LeNet de 66,87 % a 58,73 % (−8,14 pp) y elevó la de VGG de 25,10 % a 97,64 % (+72,54 pp). Con LR = 0,1, LeNet sin BN cayó a 26,96 %, mientras LeNet + BN alcanzó 66,47 %. La mejora a LR alta sugiere mayor tolerancia en LeNet, sin convergencia al 80 %.

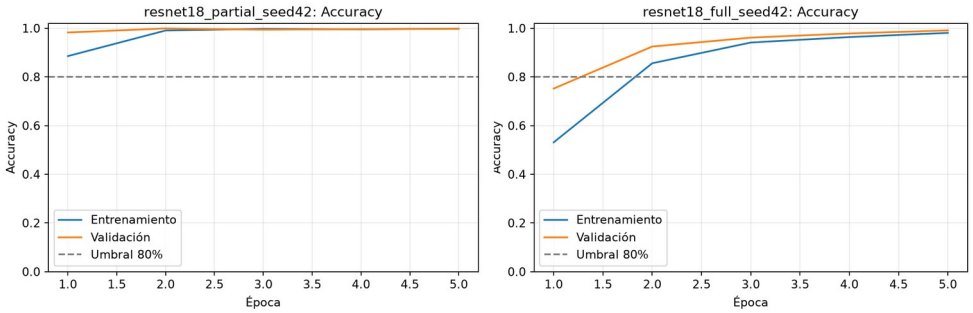
3.3. Transferencia de aprendizaje y evaluación por clase

El notebook 03 entrenó en CPU las tres estrategias ResNet-18. La Tabla 6 incorpora sus resultados y la mejor CNN desde cero del notebook 02; la comparación de segundos por época es descriptiva, pues se utilizaron dispositivos diferentes.

Tabla 6. CNN desde cero y transferencia; accuracies y macro-F1 en porcentaje.

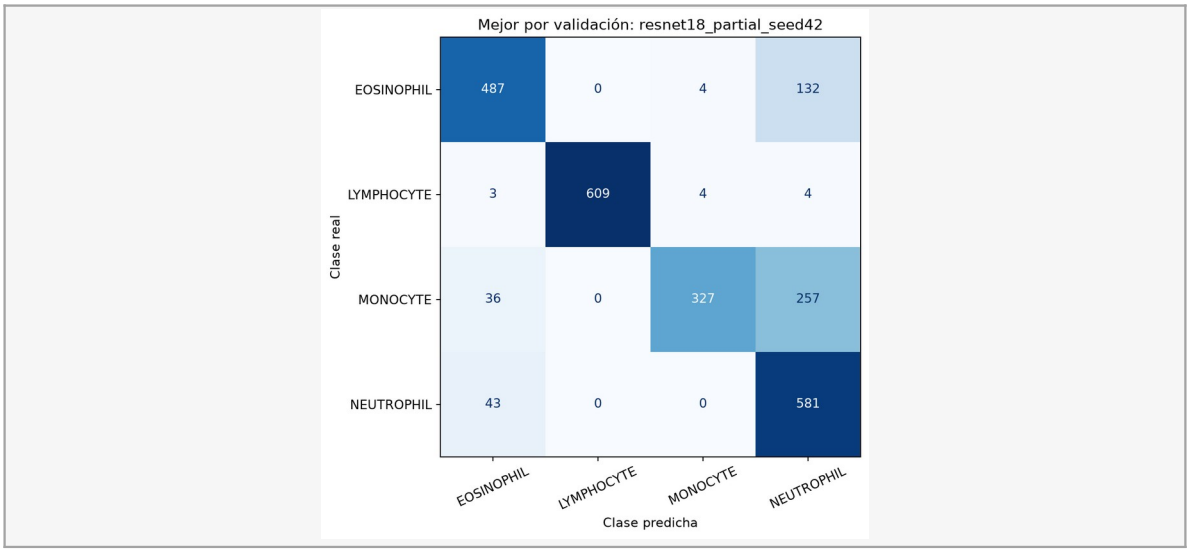
Estrategia	Parám. entr.	s/época	Acc. val.	Acc. test	Macro-F1
VGG-11 + BN (GPU)	2 966 148	23,83	97,64 %	81,14 %	82,13 %
Extracción FC (CPU)	2 052	230,35	52,26 %	40,85 %	37,73 %
Ajuste parcial (CPU)	10 495 492	381,33	99,90 %	80,58 %	80,50 %
Ajuste total (CPU)	11 178 564	674,70	99,10 %	85,32 %	85,57 %

Figura 3. Accuracy en entrenamiento y validación: ajuste parcial y total de ResNet-18 (notebook 03).



En las curvas del notebook 03, el ajuste parcial se acerca rápidamente a 100 % en validación, pero su pérdida de validación aumenta tras la segunda época; el ajuste total presenta un progreso más gradual. La extracción de características únicamente alcanzó 52,26 % en validación y 40,85 % en test.

Figura 4. Matriz de confusión en TEST de ResNet-18 con ajuste parcial, elegido por validación (notebook 03).



La matriz de confusión (Figura 4) evidencia 257 monocitos predichos como neutrófilos y 132 eosinófilos predichos como neutrófilos. El recall fue 78,17 % en EOSINOPHIL, 98,23 % en LYMPHOCYTE, 52,74 % en MONOCYTE y 93,11 % en NEUTROPHIL. La accuracy global oculta, por tanto, una debilidad notable en monocitos.

4. Discusión y análisis crítico

4.1. Validez del protocolo y alcance de las inferencias

El protocolo fijó semilla, particiones y aumentos, pero solo incluyó una semilla de entrenamiento. La brecha validación–test es relevante: ResNet parcial, 99,90 % frente a 80,58 % (19,32 pp); ResNet total, 99,10 % frente a 85,32 % (13,78 pp). Estos datos aconsejan cautela antes de afirmar generalización clínica y motivan replicaciones con más semillas.

La auditoría del notebook 01 no halló imágenes exactamente duplicadas ni hashes compartidos entre train/test. Sin embargo, los hashes no detectan muestras correlacionadas del mismo paciente ni imágenes con aumentos previos. Además, el resize cambia la proporción original; se compararon CNN a 64 × 64 con ResNet a 224 × 224, usando optimizadores y dispositivos diferentes. Así, las diferencias no aíslan el efecto causal del preentrenamiento.

4.2. Recomendación para conjuntos médicos limitados

Con el criterio fijado de validación se elige ResNet-18 parcial; con el rendimiento de test observado, el ajuste total muestra mejor accuracy, macro-F1 y, según el comentario de ejecución del notebook 03, mejor recall de monocitos. La extracción de características fue insuficiente (40,85 % test). Ante datos médicos limitados se priorizaría evaluar el ajuste total, aunque a mayor costo, y confirmar el resultado en pacientes externos.

4.3. Mejoras prioritarias

Las mejoras prioritarias son: (i) consolidar en una misma exportación las corridas del notebook 02 (GPU) y el notebook 03 (CPU), sin omitir VGG-11 + BN; (ii) repetir semillas y documentar versiones/hardware; y (iii) evaluar por paciente o centro, con particiones independientes y más atención al recall de MONOCYTE.

5. Conclusiones

El análisis de 12 444 imágenes permitió comparar seis configuraciones CNN/BN (incluidos dos controles de LR alta) y tres estrategias ResNet-18. VGG-11 + BN fue la mejor CNN desde cero: accuracy de validación 97,64 % y test 81,14 %; BN favoreció fuertemente a VGG, pero no a LeNet con la LR base.

ResNet-18 parcial maximizó la validación (99,90 %) y fue seleccionado formalmente; ResNet-18 total logró mejor resultado en test (accuracy 85,32 %; macro-F1 85,57 %). La matriz del ajuste parcial revela recall bajo en monocitos (52,74 %). El estudio es académico y exige repetir semillas, controlar la dependencia por paciente y evaluar datos externos antes de extraer conclusiones aplicables al diagnóstico.

6. Referencias

[1] Y. LeCun, L. Bottou, Y. Bengio y P. Haffner, “Gradient-based learning applied to document recognition,” Proceedings of the IEEE, vol. 86, no. 11, pp. 2278–2324, 1998. doi: 10.1109/5.726791.

[2] A. Krizhevsky, I. Sutskever y G. E. Hinton, “ImageNet classification with deep convolutional neural networks,” Advances in Neural Information Processing Systems, vol. 25, 2012.

[3] K. Simonyan y A. Zisserman, “Very deep convolutional networks for large-scale image recognition,” International Conference on Learning Representations (ICLR), 2015. Prepublicación arXiv:1409.1556, 2014.

[4] K. He, X. Zhang, S. Ren y J. Sun, “Deep residual learning for image recognition,” Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR), pp. 770–778, 2016. doi: 10.1109/CVPR.2016.90.

[5] S. Ioffe y C. Szegedy, “Batch normalization: Accelerating deep network training by reducing internal covariate shift,” Proceedings of the International Conference on Machine Learning (ICML), PMLR 37, pp. 448–456, 2015.

[6] P. T. Mooney, “Blood Cell Images,” Kaggle. Disponible en: https://www.kaggle.com/datasets/paultimothymooney/blood-cells. [Consultado: completar fecha].